


有品·数据中台·冯申杰


2019/3/29


- 1. Python是什么
 - 优缺点
 - 流行度
- 2. Hello World
 - 数据类型、运算符、输入输出、函数
 - 控制流:顺序、条件、循环、异常处理
 - 模块、标准库、第三方库
 - 一张图入门
- 3. 两个栗子
 - 爬虫:房天下二手房数据
 - ETL:数据处理
- 4.更多领域
 - 数据科学: Numpy、Pandas
 - web
- 5. 更多资料

什么是Python?

■ 简洁高效、新手友好的编程语言







■ 一种脚本语言、"解释型"语言、面向对象的高级语言。

Python is powerful... and fast;

plays well with others;

runs everywhere; is friendly & easy to learn;


is Open.

- 代码缩进决定了代码的逻辑关系
- 功能丰富的自带的库以及种类和数量繁多且强大的第 三方库
- 面向对象、过程式、函数式
- 好用的交互环境

作为解释性语言

- 优点:不需要编译即可运行
- 缺点: 性能相对不强

国外的Youtube, Instagram, Pinterest, Reddit, Dropbox, Disqus, Quora等知名应用一开始都是基于Python构建,国内的豆瓣,知乎,今日头条,果壳,饿了么,搜狐等也是Python应用的典型。



Top languages over time


https://octoverse.github.com/projects

- 1. Python是什么
 - 优缺点
 - 流行度
- 2. Hello World
 - 数据类型、运算符、输入输出、函数
 - 控制流:顺序、条件、循环、异常处理
 - 模块、标准库、第三方库
 - 一张图入门
- 3. 两个栗子
 - 爬虫:房天下二手房数据
 - ETL:数据处理
- 4.更多领域
 - 数据科学: Numpy、Pandas
 - web
- 5. 更多资料

首先按照官网指引搭建好环境,然后就可以愉快的运行Python程序了。

```
$ python # 在交互环境运行
Python 3.6.2 (v3.6.2:5fd33b5926, Jul 16 2017, 20:11:06)
[GCC 4.2.1 (Apple Inc. build 5666) (dot 3)] on darwin
Type "help", "copyright", "credits" or "license" for more information.
>>> print('hello world')
hello world
$ cat hello.py
print('hello world')
$ python hello.py # 运行py脚本
hello world
```





数据类型、运算符、输入输出、函数

■ 数据类型

- 不可变数据: Number (数字)、String (字符串)、Tuple (元组);
- 可变数据: List (列表)、Dictionary (字典)、Set (集合)。
- **运算符**: 算术、比较、赋值、逻辑等运算符
- **函数**: 将程序拆分为多个部分,使得代码的结构更加 合理。
- 值类型和引用类型

```
>>> a = [1, 2, 3] # a now references the list [1, 2, 3]
>>> b = a # b now references what a references
>>> a.append(4) # this changes the list a references
>>> print(b) # if we print what b references,
>>> [1, 2, 3, 4] # SURPRISE! It has changed...
```

控制流:顺序、条件、 循环、异常处理

- if-else
- for/while
- try-except


模块、标准库、第三 方库

- web 框架: Django/Flask/Tornado
- ORM: sqlalchemy, Peewee
- 表单验证: WTForms
- 数据处理和分析: Numpy, Pandas, Matplotlib
- 异步: celery, asyncio, tornado
- 并发: gevent, threading, concurrent.futures
- 部署: uwsgi, gunicorn
- html 处理: lxml, beautifulsoup
- 爬虫: requests, Scrapy
- 单元测试: unittest, nose, pytest
- 图片处理: pillow
- python2/3 兼容: six, 2to3
- 代码检测: autopep8, pylint, flake8, mypy(python3)
- 调试: Ipython, Ipdb, pdbpp

- 1. Python是什么
 - 优缺点
 - 流行度
- 2. Hello World
 - 数据类型、运算符、输入输出、函数
 - 控制流:顺序、条件、循环、异常处理
 - 模块、标准库、第三方库
 - 一张图入门
- 3. 两个栗子
 - 爬虫:房天下二手房数据
 - ETL:数据处理
- 4.更多领域
 - 数据科学: Numpy、Pandas
 - web
- 5. 更多资料

爬虫:房天下二手房数据

房屋面积&价位分布




http://v9.git.n.xiaomi.com/fengshenjie/fangSpider


爬虫:房天下二手房 数据

生产环境爬虫复杂得多,需要处理 包括路由、存储、分布式计算等很 多问题。

比如scrapy爬虫框架



Python在数据处理流程中的位置





minimum-template.py

ETL:数 据处理

```
# encoding: utf-8
from utils.DBEngines import engineName
from utils.base import getLogger, errHander
import getopt, os, sys
targetEngine = engineName('engineShopstat')
PROJ NAME = os.path.basename( file )
log = getLogger(PROJ NAME, logPath="/home/work/log/dataProcess/{}/".format( file ))
@errHander(PROJ_NAME)
def main():
    opts, args = getopt.getopt(sys.argv[1:], "b:e:h", ['db='])
   for op, value in opts:
        pass
    pass
if name == ' main ':
   main()
```


- 1. Python是什么
 - 优缺点
 - 流行度
- 2. Hello World
 - 数据类型、运算符、输入输出、函数
 - 控制流:顺序、条件、循环、异常处理
 - 模块、标准库、第三方库
 - 一张图入门
- 3. 两个栗子
 - 爬虫:房天下二手房数据
 - ETL:数据处理
- 4.更多领域
 - 数据科学: Numpy、Pandas
 - web
- 5. 更多资料

数据科学: Numpy、 Pandas

Python可能是通用编程语言中最灵 活的技术。

Network of Correlated Tags Visited by Python Visitors

Connections are between tags with a greater than .2 Pearson correlation in visits across Python visitors, which are defined as someone with >= 50 total visits whose most visited tag is Python.



数据科学: Numpy、 Pandas

```
, cars per cap, country, drives right
US,809, United States, True
AUS, 731, Australia, False
JAP,588, Japan, False
RU, 200, Russia, True
In [1]: import pandas as pd
In [2]: cars = pd.read csv('cars.csv', index col = 0)
In [3]: cars
Out[3]:
                          country drives right
     cars per cap
              809 United States
US
                                            True
                        Australia
AUS
              731
                                           False
```

Japan

Russia

False

True

588


200

\$ cat cars.csv

JAP

RU

```
In [6]: # Create 2 new lists height and weight
   ...: height = [1.87, 1.87, 1.82, 1.91, 1.90, 1.85]
   ...: weight = [81.65, 97.52, 95.25, 92.98, 86.18, 88.45]
   ...: import numpy as np
   ...: np_height = np.array(height) # Create 2 numpy arrays from height and weight
   ...: np weight = np.array(weight)
   ...: print(type(np height))
<class 'numpy.ndarray'>
In [7]: bmi = np weight / np height ** 2 # Calculate bmi
   ...: print(bmi)
   . . . :
[23.34925219 27.88755755 28.75558507 25.48723993 23.87257618 25.84368152]
In [8]: bmi[bmi > 23] # Print only those observations above 23
   . . . :
Out[8]:
array([23.34925219, 27.88755755, 28.75558507, 25.48723993, 23.87257618,
       25.84368152])
                                                              Python List
                                            Numpy Array
```




Web框架

比如 Django、Flask、Tornado 等.

- 知乎到 2010 年 12 月份上线时,工程师是四个。初期的架构选型使用的是<u>Tornado</u>框架。
 - 简单轻量,学习成本低
 - 社区支持,有 FriendFeed 的成熟案例
 - 实时推送 Feed 和通知需要跟浏览器端建立一个长连接

运行效率较低。机房机柜空间已经不足; **语言过于灵活**,多人协作和项目维护成本较高。

从 0 到 100——知乎架构变迁史, 2014 知乎社区核心业务 Golang 化实践, 2018



- 1. Python是什么
 - 优缺点
 - 流行度
- 2. Hello World
 - 数据类型、运算符、输入输出、函数
 - 控制流:顺序、条件、循环、异常处理
 - 模块、标准库、第三方库
 - 一张图入门
- 3. 两个栗子
 - 爬虫:房天下二手房数据
 - ETL:数据处理
- 4.更多领域
 - 数据科学: Numpy、Pandas
 - web
- 5. 更多资料

Python代码的执行由Python 虚拟机 (也叫解释器主循环)来控制。 对Python 虚拟机的访问由全局解释 器锁(GIL)来控制。

PVM是Python的运行引擎,是迭代运行字节码指令的一个大循环,一个接一个的完成操作。

main.py

```
def foo():
    x = 1
    def bar(y):
        z = y + 2 # <--- (3) ... and the interpreter is here.
        return z
    return bar(x) # <--- (2) ... which is returning a call to bar ...
foo() # <--- (1) We're in the middle of a call to foo ...</pre>
```

call stack / block stack / data stack :

谢谢

更多资料

- https://cn.udacity.com/course/intro-to-pythonnanodegree--nd302-cn-basic
- https://www.learnpython.org/
- https://morvanzhou.github.io/tutorials/datamanipulation/np-pd/
- 人们对Python在企业级开发中的10大误解
- Python解释器简介(5): 深入主循环
- 书单: https://python-web-guide.readthedocs.io/zh/latest/base/basics.html